

Universidade Estadual de Maringá

Departamento de Estatística

Disciplina: 7210 – Modelos Não Lineares

Professor: Dr. Josmar Mazucheli

Acadêmico: André Felipe Berdusco Menezes

***Antibodies Anticoronavirus Assayed by an
ELISA Test:
Comparing Several Response Curves***

1 Introdução

Neste trabalho será apresentada a análise dos dados referente a seção 1.1.3 (*Antibodies Anticoronavirus Assayed by an ELISA Test: Comparing Several Response Curves*) do livro escrito por Huet et al. (2004).

Este conjunto de dados é proveniente de um experimento o qual utilizou-se um teste ELISA¹ para detectar a presença de anticorpos no soro de bezerros e vacas. O problema se restringe à comparação dos níveis de anticorpos em duas amostras de soro colhidas em Maio e Junho de uma determinada vaca. Assim, a variável resposta refere-se aos resultados do teste ELISA, nos quais são uma coleção de densidades ópticas observadas para diferentes diluições de soro.

Uma representação gráfica dos dados é apresentada na Figura 1. Nota-se um comportamento decrescente da densidade ótica conforme o aumento no log da diluição, entretanto esta conduta decrescente é identificada como sendo uma curva sigmoide, ou seja, uma curva com formato de S ou S invertido.




Figura 1: Comportamento da variável resposta conforme a covariável (log-diluição) e o mês.

¹Enzyme-Linked Immunosorbent Assay: é um teste imunoenzimático que permite a detecção de anticorpos específicos

2 Metodologia

Os modelos de regressão, em sua forma univariada, são utilizados para descrever o comportamento de uma variável aleatória Y , como uma função condicional a(s) variável(is) explicativa(s) \mathbf{x} . Em particular, nos modelos não lineares a relação entre Y e \mathbf{x} é descrita por uma função esperança não linear nos parâmetros. Explicitamente temos:

$$\mathbb{E}(Y \mid \mathbf{x}) = f(\mathbf{x}, \boldsymbol{\theta}) + \varepsilon \quad (1)$$

em que \mathbf{x} é o vetor de variável explicativa, $\boldsymbol{\theta}$ é o vetor de parâmetros desconhecidos e ε é o vetor de efeitos aleatórios. Em geral, assume-se que os erros são variáveis aleatórias independentes e identicamente distribuídas normais com média $\mathbf{0}$ e variância constante σ^2 . Consequentemente, conforme propriedades da distribuição Normal temos que:

$$Y \mid \mathbf{x} \sim N(f(\mathbf{x}, \boldsymbol{\theta}), \sigma^2) \quad (2)$$

Assim, inferências para o vetor de parâmetros $\boldsymbol{\theta}$ podem ser realizada sob o paradigma da verossimilhança (ver, por exemplo, Lehmann and Casella, 1998; Pawitan, 2001). Supondo o pressuposto estabelecido em (2) e dada uma amostra aleatória da forma $(y_i, x_{ip}), i = 1, \dots, n$ e $p < n$, a função de verossimilhança para $\boldsymbol{\theta}$ e σ^2 pode ser escrita na forma:

$$L(\boldsymbol{\theta}, \sigma^2 \mid \mathbf{y}, \mathbf{x}) = (2\pi)^{-n/2} (\sigma^2)^{-n/2} \prod_{i=1}^n \exp \left[-\frac{1}{2\sigma^2} (y_i - f(x_i, \boldsymbol{\theta}))^2 \right] \quad (3)$$

Logo, a bem conhecida log-verossimilhança é dada por:

$$\ell(\boldsymbol{\theta}, \sigma^2 \mid \mathbf{y}, \mathbf{x}) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{\theta}))^2 \quad (4)$$

As estimativas de máxima verossimilhança, $\hat{\boldsymbol{\theta}}$ e $\hat{\sigma}^2$ são obtidas maximizando (4) em relação a $\boldsymbol{\theta}$ e σ^2 . Testes de hipóteses e intervalos de confiança para os parâmetros são realizados a partir das propriedades assintóticas dos estimadores de máxima verossimilhança (Lehmann and Casella, 1998).

No que tange o problema descrito na seção anterior os autores assumem que a relação entre a densidade óptica, Y , e o logaritmo da diluição, $x = \log_{10}(1/d)$, é modelada por uma curva sigmoide. Além disso, a função esperança considerada é definida pela expressão:

$$f(x, \boldsymbol{\theta}) = \theta_1 + \frac{\theta_2 - \theta_1}{1 + \exp[\theta_3(x - \theta_4)]} \quad (5)$$

em que $\boldsymbol{\theta} = (\theta_1, \theta_2, \theta_3, \theta_4)^\top$ é o vetor de parâmetros. O livro não apresenta a interpretação dos parâmetros, entretanto na obra de Pinheiro and Bates (2000) é possível encontrar o significado de cada parâmetro, dado por:

- θ_1 : a assíntota horizontal quando $x \rightarrow \infty$;
- θ_2 : a assíntota horizontal quando $x \rightarrow -\infty$;
- θ_3 : o valor de x no ponto de inflexão. Neste valor de x a variável resposta esta no meio da assíntota;
- θ_4 : parâmetro de escala

É importante lembrar que o principal intuito do estudo é comparar as curvas ajustadas no mês de Maio e Junho, afim de verificar se os dois soros contem o mesmo constituinte eficaz, conforme os termos técnicos queremos avaliar a hipótese de paralelismo entre as curvas. Dessa forma, a seguinte hipótese estatística deve ser avaliada:

$$\begin{cases} \mathcal{H}_0 : \boldsymbol{\theta}^{\text{May}} = \boldsymbol{\theta}^{\text{June}} \\ \mathcal{H}_1 : \boldsymbol{\theta}^{\text{May}} \neq \boldsymbol{\theta}^{\text{June}} \end{cases} \quad (6)$$

sendo que $\boldsymbol{\theta}^{\text{May}}$ e $\boldsymbol{\theta}^{\text{June}}$ denotam o vetor de parâmetros $\boldsymbol{\theta} = (\theta_1, \theta_2, \theta_3)^\top$ do mês de Maio e Junho, respectivamente. Note que o parâmetro de escala θ_4 não foi considerado pelos autores para comparar as curvas.

A suposição de paralelismo entre as curvas é importante, pois os autores também estão interessados na quantidade $\rho = g(\boldsymbol{\theta}) = 10^{-(\theta_4^{\text{May}} - \theta_4^{\text{June}})}$. Esta quantidade é função dos parâmetros e quantifica a potência do soro tomada em Junho em relação ao soro tomado em Maio. Portanto, se $\rho = 1$ temos evidências amostrais que não existe potência de um soro relativo a outro soro. Em termos estatísticos a hipótese a ser avaliada é expressa por:

$$\begin{cases} \mathcal{H}_0 : \rho = 1 \\ \mathcal{H}_1 : \rho \neq 1 \end{cases} \quad (7)$$

Para testar as hipótese especificadas em (6) e (7) os testes da razão de verossimilhança e Wald serão utilizados. A estatística destes testes são definidas, respectivamente, por:

$$S_{LR} = 2(\ell_c - \ell_r) \quad (8)$$

e

$$S_W = \left(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0\right)^T \mathbf{I}(\hat{\boldsymbol{\theta}}) \left(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0\right) \quad (9)$$

em que ℓ_r e ℓ_c são os valores das funções de log-verossimilhanças avaliadas sob hipótese nula e alternativa, respectivamente, e $\mathbf{I}(\hat{\boldsymbol{\theta}})$ denota a matriz de informação esperada localmente nas estimativas de máxima verossimilhança. Sob a hipótese nula, ambos os testes tem distribuição assintótica qui-quadrado com p graus de liberdade, sendo p o número de restrições impostas.

Note que estes testes e toda inferência realizada sob os parâmetros do modelo (2) assumem que o mesmo possui uma linearidade local e que as estimativas dos parâmetros são normalmente distribuídas. Na prática essas suposições podem não ser satisfeita, principalmente para pequenas amostras, uma alternativa é o uso de técnicas não paramétricas de reamostragem, tais como o Bootstrap e Jackknife (Efron, 1982). Neste trabalho a função `nlsBoot` da biblioteca `nlstools` (Baty et al., 2015) foi utilizada como alternativa a inferência clássica.

As análises foram conduzidas nos softwares **SAS** e **R**, usando os procedimentos **PROC NLIN** (SAS, 2010a) e **PROC NLMIXED** (SAS, 2010b) no **SAS**, já no **R** a função `nls` e a biblioteca `nlstools`, como mencionado anteriormente, foram utilizadas.

3 Resultados

Nesta seção serão apresentados os resultados relacionados a análise do dados descritos na seção anterior, os mesmo resultados estão nas seções 1.4.3 e 2.4.3 do livro de Huet et al. (2004). Utilizando o método da máxima verossimilhança estimamos os parâmetros do modelo (5) para os meses de Maio e Junho. Pelas propriedades assintótica dos EMV's foi possível mensurar a precisão das estimativas, além disso, foi computado também os intervalos de confiança Bootstrap, estes resultados estão expostos na Tabela 1.

Tabela 1: Estimativas dos parâmetros, erro padrão assintótico e intervalos de confiança.

Parâmetro	Estimativa	EP	Assintótico		Bootstrap	
			LI	LS	LI	LS
θ_1^{May}	0.0424	0.0215	-0.0014	0.0862	0.0020	0.0770
θ_2^{May}	1.9367	0.0133	1.9096	1.9637	1.9117	1.9613
θ_3^{May}	2.5649	0.0971	2.3672	2.7627	2.3975	2.7522
θ_4^{May}	3.4672	0.0158	3.4350	3.4994	3.4384	3.4961
θ_1^{June}	0.0581	0.0164	0.0247	0.0914	0.0240	0.0882
θ_2^{June}	1.9088	0.0137	1.8809	1.9368	1.8809	1.9360
θ_3^{June}	2.8365	0.1059	2.6208	3.0522	2.6412	3.0283
θ_4^{June}	3.2507	0.0136	3.2230	3.2785	3.2253	3.2781

Observando o intervalo de confiança assintótico para o parâmetro θ_1^{May} nota-se que o mesmo contém o valor zero. Por outro lado, o intervalo Bootstrap apresentou menor amplitude e mostrou que o parâmetro é diferente de zero. Os outros parâmetros foram todos diferentes de zero e positivos e os intervalos de confiança assintóticos e Bootstrap apresentaram resultados similares. As curvas ajustadas estão apresentadas na Figura 2. Pode-se notar que a densidade óptica é maior no mês de Maio do que no mês de Junho.




Figura 2: Curvas ajustadas conforme o mês de Maio e Junho.

Com finalidades de comparação gráfica entre os dois meses foi sobreposto as curvas ajustadas com suas respectivas bandas de confiança e os valores observados na Figura 3.

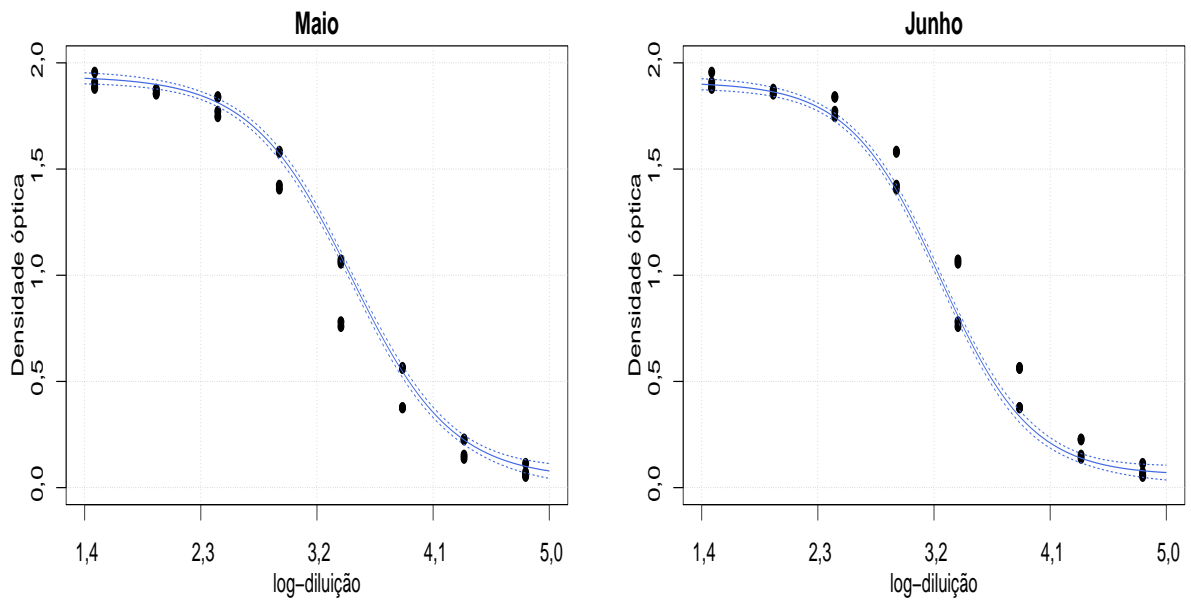


Figura 3: Curvas ajustadas e bandas de confiança conforme o mês de Maio e Junho.

Para testar a hipótese definida em (6) vamos utilizar os testes da razão de verossimilhanças (8) e Wald (9). Ressalta-se que caso haja evidências amostrais para rejeição

da hipótese nula, pode-se concluir que as curvas do mês de Maio e Junho são estatisticamente diferentes. Os comandos utilizados tanto no SAS quanto no R estão disponíveis no Apêndice, além disso os resultados estão expostos na Tabela 2.

Tabela 2: Resultados dos testes para a hipótese (6).

Teste	GL	Estatística	valor- p
S_W	3	4.6866	0.1962
S_{LR}	3	4.4389	0.2178

Assim, com base na amostra selecionada podemos inferir que ambas as curvas são estatisticamente iguais, uma vez que em ambos os testes não encontramos evidência para rejeitar a hipótese nula (6).

Como discutido na metodologia deste trabalho os autores tiveram o interesse em estimar a seguinte função dos parâmetros $\rho = g(\boldsymbol{\theta}) = 10^{-(\theta_4^{\text{May}} - \theta_4^{\text{June}})}$. Sob o ponto de vista de inferência clássica ρ é estimado utilizando a propriedade de invariância dos estimadores de máxima verossimilhança. Portanto, a estimativa pontual da potência ρ do soro tomada em junho em relação ao soro tomado em maio é $\hat{\rho} = 10^{-(3.4672 - 3.2507)} = 0.6075$.

Afim de testar a significância estatística de $\hat{\rho}$ os autores testaram, sob um diferente ponto de vista, a hipótese nula definida em (7). Note que testar a hipótese (7) é equivalente a testar $\mathcal{H}_0 : \beta = 0$ versus $\mathcal{H}_1 : \beta \neq 0$, em que $\beta = \theta_4^{\text{May}} - \theta_4^{\text{June}}$. Assim, ao invés de testar se $\rho = 0$ os autores realizaram o teste sobre β . Considerando a estatística da razão de verossimilhanças obtemos que $S_{LR} = 47,3401$ e o valor- $p < 0,000$. Logo, podemos concluir que ρ é estatisticamente significativo. Vale pontuar que os códigos utilizados para testar determinada hipótese encontram-se no Apêndice deste trabalho.

Por fim, os autores também calculam o intervalo de confiança assintótico (Wald) e Bootstrap para o parâmetro ρ . Foi considerado $B = 1000$ amostras, na Tabela 3 é apresentado os resultados de ambos intervalos de confiança.

Tabela 3: Intervalos de 95% de confiança assintótico e Bootstrap para o parâmetro ρ .

Método	Limites		Amplitude
	Inferior	Superior	
Assintótico	0.5503	0.6647	0.1144
Bootstrap	0.5543	0.6634	0.1091

A distribuição empírica Bootstrap de ρ é apresentada na Figura 4. A linha tracejada em vermelho indica a estimativa pontual de ρ , já as linhas em preto representam o intervalo de 95% de confiança baseado nas B amostras Bootstrap.




Figura 4: Distribuição empírica Bootstrap de ρ .

Observa-se que o intervalo Bootstrap obteve uma amplitude um pouco menor que o intervalo assintótico. Do ponto de vista prático não há diferenças consideráveis aos métodos.

4 Considerações finais

O presente trabalho refez a análise dos dados referentes a seção 1.1.3 do livro Huet et al. (2004). Os mesmos resultados encontrados nas seções 1.4.3 e 2.4.3 estão apresentados neste texto. As análises foram desenvolvidas em ambos os softwares **R** e **SAS** e os códigos estão disponíveis no Apêndice.

O principal objetivo da análise era comparar os níveis de anticorpos em duas amostras de soro colhidas em Maio e Junho. Assim, foi considerado o modelo logístico com quatro parâmetros (Pinheiro and Bates, 2000) e realizado testes sobre os parâmetros dos modelos. Os resultados indicaram que as curvas possuem um comportamento de paralelismo, dessa forma foi possível estimar a diferença, $\beta = \theta_4^{\text{May}} - \theta_4^{\text{June}}$, a qual foi de 0.223. Na sequência, foi obtido estimativas pontuais e intervalares de ρ , e conclui-se que a potência do soro tomada em Junho em relação ao soro tomado em Maio é 0.6075, sendo seu intervalo assintótico de 95% de confiança dado por (0.5503, 0.6647).

Referências

- Baty, F., Ritz, C., Charles, S., Brutsche, M., Flandrois, J.-P., Delignette-Muller, M.-L., 2015. A toolbox for nonlinear regression in R: The package nlstools. *Journal of Statistical Software* 66 (5), 1–21.
- Efron, B., 1982. The Jackknife, the Bootstrap and other resampling plans. Vol. 38. SIAM.
- Huet, S., Bouvier, A., Poursat, M.-A., Jolivet, E., 2004. *Statistical Tools for Nonlinear Regression: A Practical Guide with S-PLUS and R Examples*. Springer.
- Lehmann, E. J., Casella, G., 1998. *Theory of Point Estimation*. Springer Verlag.
- Pawitan, Y., 2001. In *All Likelihood: Statistical Modelling and Inference Using Likelihood*. Oxford University Press, Oxford.
- Pinheiro, J. C., Bates, D. M., 2000. *Mixed-Effects Models in S and S-PLUS*. Springer.
- SAS, 2010a. *The NLIN Procedure, SAS/STAT® User’s Guide, Version 9.4*. Cary, NC: SAS Institute Inc.
- SAS, 2010b. *The NLMIXED Procedure, SAS/STAT® User’s Guide, Version 9.4*. Cary, NC: SAS Institute Inc.

Apêndice

Todos os resultados apresentados neste trabalho foram obtidos utilizando os softwares R e SAS. Neste apêndice exibimos os códigos utilizados em ambos softwares.

Código 1: Códigos utilizados no R

```
1  ##-----
2  rm(list = ls())
3  library(nlstools)
4
5  # Conjunto de dados -----
6  dilution <- rep(c(rep(30,2), rep(90,2), rep(270,2), rep(810,2), rep(2430,2), rep(7290,2),
7    rep(21869,2), rep(65609,2)), 2)
8  elisa <- data.frame(logd=log10(dilution),
9    OD = c(1.909, 1.956, 1.856, 1.876, 1.838, 1.841, 1.579,
10    1.584, 1.057, 1.072, 0.566, 0.561, 0.225, 0.229,
11    0.072, 0.114, 1.886, 1.880, 1.853, 1.870, 1.747,
12    1.772, 1.424, 1.406, 0.781, 0.759, 0.377, 0.376,
13    0.153, 0.138, 0.053, 0.058),
14    month = c(rep("may", 16), rep("june", 16)))
15  elisa$month <- factor(elisa$month)
16  elisa$month <- relevel(elisa$month, 'may')
17
18  # Ajuste do modelo -----
19  mod.c <- OD ~ theta1[month] + (theta2[month] - theta1[month]) / (1 + exp(theta3[month] *
20    (logd - theta4[month])))
21  ini.c <- list(theta1 = c(0.05, 0.05), theta2 = c(1.9, 1.9), theta3 = c(2.5, 2.5), theta4
22    = c(3.2, 3.2))
23  elisa.c <- nls(formula = mod.c, data = elisa, start = ini.c)
24  summary(elisa.c)
25
26  # Ajuste separado e IC bootstrap -----
27  elisa.may <- nls(formula = mod.r, data = subset(elisa, month == 'may'), start = ini.r)
28  summary(elisa.may)
29  elisa.june <- nls(formula = mod.r, data = subset(elisa, month == 'june'), start = ini.r)
30  summary(elisa.june)
31
32  boot.may <- nlsBoot(elisa.may)
33  boot.june <- nlsBoot(elisa.june)
34
35  est <- rbind(tidy(elisa.may), tidy(elisa.june))[, -c(4, 5)]
36  icb <- rbind(boot.may$bootCI, boot.june$bootCI)[, -1]
37  fim <- cbind(est, icb)
38  print(xtable(fim, digits = 4))
39
40  # Grafico com as curvas ajustadas -----
41  fx <- function(x, theta)
42  {
43    theta1 <- theta[1]; theta2 <- theta[2]; theta3 <- theta[3]; theta4 <- theta[4]
44    theta1 + (theta2 - theta1) / (1 + exp(theta3 * (x - theta4)))
45  }
46  x <- seq(1.4, 5, l = 1000)
47  theta.may <- coef(elisa.may)
48  theta.june <- coef(elisa.june)
49  fx.may <- fx(x, theta.may)
50  fx.june <- fx(x, theta.june)
```

```

50
51 plot(OD ~ logd, col = c('royalblue', 'orangered')[month], data = elisa, pch = 19, xlim =
      c(1.4, 5), ylim = c(0, 2), cex = 0.6)
52 lines(fx.may ~ x, lwd = 2, col = 'orangered')
53 lines(fx.june ~ x, lwd = 2, col = 'royalblue')
54 abline(h=seq(0, 2, l = 5), v=seq(1.4, 5, l = 5), col = 'gray', lty = 'dotted')
55 legend('topright', legend = c('Maio', 'Junho'),
56       col = c('orangered', 'royalblue'), lwd = 1.4, pch = 19, bty = 'n', inset = 0.02,
       cex = 0.6)
57
58 # Testando a hipotese (6) -----
59 modH0 <- OD ~ theta1 + (theta2 - theta1)/(1 + exp(theta3 * (logd - theta4[month])))
60 modH1 <- OD ~ theta1[month] + (theta2[month] - theta1[month])/(1 + exp(theta3[month] * (
      logd - theta4[month])))
61
62 fitH0 <- nls(modH0, data = elisa, start = list(theta1 = 0.05, theta2 = 1.9, theta3 = 2.5,
      theta4 = c(3.2, 3.2)))
63 fitH1 <- nls(modH1, data = elisa, start = list(theta1 = c(0.05, 0.05), theta2 = c(1.9,
      1.9), theta3 = c(2.5, 2.5), theta4 = c(3.2, 3.2)))
64
65 anova(fitH0, fitH1)
66 ll_H0 <- as.numeric(logLik(fitH0))
67 ll_H1 <- as.numeric(logLik(fitH1))
68 S_LR <- 2 * (ll_H1 - ll_H0)
69 c(S_LR, pchisq(S_LR, df = 3, lower.tail = F))
70
71 theta_hat <- diff(coef(fitH1)[-c(7, 8)])[-c(2, 4)]
72 I_may <- vcov(fitH1)[c('theta11', 'theta21', 'theta31'), c('theta11', 'theta21', '
      theta31')]
73 I_june <- vcov(fitH1)[c('theta12', 'theta22', 'theta32'), c('theta12', 'theta22', '
      theta32')]
74 I_hat <- I_may + I_june
75 S_W <- theta_hat %*% solve(I_hat) %*% theta_hat
76 c(S_W, pchisq(S_W, df = 3, lower.tail = F))
77
78 # Intervalo de confianca Bootstrap para rho -----
79 rho <- function(theta4_may, theta4_june){
80   10^(-(theta4_may - theta4_june))
81 }
82 rho.hat <- rho(coef(elisa.c)['theta41'], coef(elisa.c)['theta42'])
83 set.seed(1212)
84 B <- 1000
85 boot.may <- nlsBoot(nls = elisa.may, niter = B)
86 boot.june <- nlsBoot(nls = elisa.june, niter = B)
87 theta4.may.boot <- boot.may$coefboot[, 4]
88 theta4.june.boot <- boot.june$coefboot[, 4]
89
90
91 rho.boot <- ldply(lapply(1:B, function(i) rho(theta4.may.boot[i], theta4.june.
      boot[i])))$V1
92 quantile(rho.boot, c(0.025, 0.975), na.rm = T)

```

Código 2: Códigos utilizados no SAS

```

1  /* Importando dados */
2  proc import out = elisa replace
3      datafile = '...\elisa.txt'
4      dbms = tab;
5      getnames = yes;
6  run;
7
8  /*Ajuste do modelo usando a PROC NLIMIXED*/
9  proc nlmixed data = elisa df = 999999 tech = quanew cov;
10     parms theta1_may = 0.05, theta2_may = 1.9, theta3_may = 2.5, theta4_may =
11         3.2, theta1_june = 0.05, theta2_june = 1.9, theta3_june = 2.5, theta4_june =
12         3.2, sigma = 1;
13     bounds sigma > 0;
14     if(month = 'may') then do;
15         mean = theta1_may + (theta2_may - theta1_may) / (1 + exp(theta3_may * (logd -
16             theta4_may)));
17     end; else do;
18         mean = theta1_june + (theta2_june - theta1_june) / (1 + exp(theta3_june * (logd -
19             theta4_june)));
20     end;
21     ll = - 0.5 * log(2*constant("pi")) - 0.5 * log(sigma**2) - 0.5 / sigma**2 * (od -
22         mean)**2;
23     model od ~ general(ll);
24     estimate 'beta' theta4_may - theta4_june;
25     estimate 'rho' 10*(-(theta4_may - theta4_june));
26     predict mean out = media;
27 run;
28
29 /*Ajuste do modelo usando a PROC NLIN*/
30 proc nlin data = elisa tech = quanew;
31     parms theta1_may = 0.05, theta2_may = 1.9, theta3_may = 2.5, theta4_may =
32         3.2,
33     theta1_june = 0.05, theta2_june = 1.9, theta3_june = 2.5, theta4_june = 3.2;
34     if(month = 'may') then do;
35         mean = theta1_may + (theta2_may - theta1_may) / (1 + exp(theta3_may * (logd -
36             theta4_may)));
37     end; else do;
38         mean = theta1_june + (theta2_june - theta1_june) / (1 + exp(theta3_june * (logd -
39             theta4_june)));
40     end;
41     model od = mean;
42 run;
43
44 /*Testando a hipotese -> H_0: theta_may = theta_june vs. H_1: theta_may != theta_june*/
45
46 * Modelo completo;
47 proc nlmixed data = elisa df=99999 tech = quanew;
48     parms theta1_may = 0.05, theta2_may = 1.9, theta3_may = 2.5, theta4_may =
49         3.2,
50     theta1_june = 0.05, theta2_june = 1.9, theta3_june = 2.5, theta4_june = 3.2,
51     sigma = 1;
52     bounds sigma > 0;
53     if(month = 'may') then do;
54         mean = theta1_may + (theta2_may - theta1_may) / (1 + exp(theta3_may * (logd -
55             theta4_may)));
56     end; else do;
57         mean = theta1_june + (theta2_june - theta1_june) / (1 + exp(theta3_june * (logd -
58             theta4_june)));
59     end;
60     model od ~ general(mean);
61     ll = - 0.5 * log(2*constant("pi")) - 0.5 * log(sigma**2) - 0.5 / sigma**2 * (od -
62         mean)**2;
63     model od ~ general(ll);
64     estimate 'beta' theta4_may - theta4_june;
65     estimate 'rho' 10*(-(theta4_may - theta4_june));
66     predict mean out = media;
67 run;

```

```

47     end;
48     ll = - 0.5 * log(2*constant("pi")) - 0.5 * log(sigma**2) - 0.5 / sigma**2 * (od -
        mean)**2;
49     model od ~ general(ll);
50     contrast 'theta_may=theta_june' theta1_may - theta1_june, theta2_may - theta2_
        june, theta3_may - theta3_june;
51     ods output Contrasts = Wald(drop = label DenDF rename = (NumDF = df FValue = est
        ProbF = pvalue));
52     ods output FitStatistics = H1(rename = (value = llh1 ) where = (descr = '-2Log
        Likelihood'));
53 quit;
54
55 * Modelo restrito;
56 proc nlmixed data = elisa df=99999 tech = quanew;
57     parms theta1 = 0.05, theta2 = 1.9, theta3 = 2.5, theta4_may = 3.2, theta4_
        june = 3.2, sigma = 1;
58     bounds sigma >0;
59     if(month = 'may') then do;
60     mean = theta1 + (theta2 - theta1) / (1 + exp(theta3 * (logd - theta4_may)));
61     end; else do;
62     mean = theta1 + (theta2 - theta1) / (1 + exp(theta3 * (logd - theta4_june)));
63     end;
64     ll = - 0.5 * log(2*constant("pi")) - 0.5 * log(sigma**2) - 0.5 / sigma**2 * (od -
        mean)**2;
65     model od ~ general(ll);
66     ods output FitStatistics = H0(rename = (value = llh0 ) where = (descr = '-2Log
        Likelihood'));
67 run;
68
69 * Ajuste dos resultados;
70 data LR(drop = Descr llH0 llH1);
71     merge H0 H1;
72     df
73     = 3;
74     Est
75     = llH0 - llH1;
76     pvalue
77     = 1 - cdf('CHISQUARE', Est, df);
78 run;
79
80 data wald;
81     set wald;
82     est = df * est;
83 run;
84
85 data testes;
86     set Wald LR;
87 run;
88
89 * Exibindo resultados;
90 proc print data = testes noobs;
91     format _numeric_ comma10.4;
92 run;

```